

MBA
USP
ESALQ

Modelo preditivo para identificação da melhor
condução no tratamento de doenças mentais

Renata de Oliveira Valentim

Dra. Gabrielle Maria Romeiro Lombardi

Índice

Introdução

Objetivo

Materiais e métodos

Resultados e discussão

Considerações finais

Introdução



Introdução


Prevalência

2019:

≈ 970 milhões de pessoas no mundo com transtornos mentais

Pós pandemia:

↑ 25% na prevalência de transtornos mentais



+ prevalentes:

Depressão
Ansiedade

♀ ♂


→ Transtorno de Ansiedade Generalizada

→ Transtorno de Pânico


≈ duas vezes mais em mulheres do que em homens

Introdução

Impactos



Fonte: Ministério da Previdência Social



Entre 2014 e 2024:
mais de 470 mil afastamentos no Brasil foram atribuídos a transtornos mentais

Introdução

Transtornos mentais

Transtorno Depressivo Maior: TDM Perda de prazer em atividades diárias, alterações no apetite e no sono	Transtorno Bipolar: TB Oscilações de humor entre episódios de mania e depressão
Transtorno de Ansiedade Generalizada: TAG Preocupações excessivas e persistentes	Transtorno de Pânico: TP Crises súbitas de medo intenso

Tratamentos	Limitações:
• Medicamentos: antidepressivos e ansiolíticos, por exemplo • Terapias psicossociais: Terapia Cognitivo-Comportamental (TCC), psicanálise, por exemplo	Integração de variáveis genéticas, ambientais e comportamentais, o que pode comprometer a eficácia terapêutica.

Introdução

Dados clínicos em saúde

Integrar as terapias tradicionais com soluções inovadoras

Uso de IA para prever quais combinações de tratamento serão mais eficazes para cada paciente



Análise de grandes volumes de dados clínicos, comportamentais e genéticos

Ferramentas podem apoiar médicos e farmacêuticos:

- escolha de medicamentos
- ajuste de dosagens
- prevenção de interações perigosas



Objetivo

Desenvolver um modelo preditivo capaz de identificar a combinação mais eficaz de tratamento, psicoterapia e exercício físico para pacientes com TDM, TAG, TB e TP, considerando variáveis como idade e gênero



Material e métodos

Mental Health Diagnosis and Treatment Monitoring

kaggle

Mental health diagnosis, treatment, and monitoring dataset

Data Card

Code (12)

Discussion (0)

Suggestions (0)

About Dataset

Mental Health Diagnosis and Treatment Monitoring Dataset

Overview

The **Mental Health Diagnosis and Treatment Monitoring** dataset contains 500 rows representing real-world mental health diagnoses, treatment plans, and outcomes. It includes patient demographics, symptom severity, medication, therapy types, and progress tracking. **This dataset is synthetic and created for research and analysis purposes.**

Material e métodos


Termo original em inglês descrito no dataset	Tradução livre (adotada neste trabalho)	Tipo de dado
Patient ID	ID do Paciente	Inteiro/ Numérico
Age	Idade	Inteiro/ Numérico
Gender	Gênero	Texto/Categórico
Diagnosis	Diagnóstico	Texto/Categórico
Symptom Severity (1-10)	Gravidade dos Sintomas (1-10)	Inteiro/ Numérico
Mood Score (1-10)	Pontuação de Humor (1-10)	Inteiro/ Numérico
Sleep Quality (1-10)	Qualidade do Sono (1-10)	Inteiro/ Numérico
Physical Activity (hrs/week)	Atividade Física (horas/semana)	Inteiro/ Numérico
Medication	Medicação	Texto/Categórico
Therapy Type	Tipo de Terapia	Texto/Categórico
Treatment Start Date	Data de Início do Tratamento	Texto/Categórico
Treatment Duration (weeks)	Duração do Tratamento (semanas)	Inteiro/ Numérico
Stress Level (1-10)	Nível de Estresse (1-10)	Inteiro/ Numérico
Outcome	Resultado	Texto/Categórico
Treatment Progress (1-10)	Progresso do Tratamento (1-10)	Inteiro/ Numérico
AI-Detected Emotional State	Estado Emocional Detectado por IA	Texto/Categórico
Adherence to Treatment (%)	Adesão ao Tratamento (%)	Inteiro/ Numérico

Key Features

- **Patient ID:** Unique identifier.
- **Age:** Age of the patient.
- **Gender:** Male or Female.
- **Diagnosis:** Mental health condition (e.g., Anxiety, Depression).
- **Symptom Severity (1-10):** Severity of symptoms.
- **Mood Score (1-10):** Mood rating during treatment.
- **Sleep Quality (1-10):** Patient-reported sleep quality.
- **Physical Activity:** Hours per week of activity.
- **Medication:** Medications prescribed (e.g., SSRIs, Antidepressants).
- **Therapy Type:** Type of therapy (e.g., CBT, DBT).
- **Treatment Start Date:** Date treatment started.
- **Treatment Duration:** Duration of treatment in weeks.
- **Stress Level (1-10):** Patient's stress level.
- **Outcome:** Treatment outcome (e.g., Improved, Deteriorated).
- **Treatment Progress (1-10):** Progress made during treatment.
- **AI-Detected Emotional State:** AI-detected emotional state (e.g., Happy, Anxious).
- **Adherence to Treatment (%):** Percentage of adherence to treatment plan.

Material e métodos

Análise Exploratória de Dados (EDA)




Compreender melhor as relações entre as variáveis presentes no dataset:

- Análise de distribuição de variáveis como idade, gênero, diagnóstico, tipo de medicação, terapia aplicada e exercício físico
- Identificação de correlações entre a taxa de sucesso do tratamento e os diferentes fatores (idade, gênero, diagnóstico, tipo de medicação, terapia e exercício físico)
- Visualizações gráficas para explorar padrões e outliers, utilizando ferramentas como matplotlib e seaborn no Python
- Testes estatísticos, como o ANOVA ou t-test, para verificar a significância das diferenças entre grupos de tratamentos e terapias

Material e métodos

Modelagem preditiva



Modelo	Motivo de uso
Regressão Logística	prever a probabilidade de sucesso do tratamento
Random Forest	capturar relações não lineares entre as variáveis
Gradient Boosting	melhorar a acurácia das previsões

Validação do modelo: divisão dos dados em conjuntos de treino e teste

Desempenho: avaliado por métricas como AUC (Área Sob a Curva ROC), precisão, recall e F1-score

Resultados e discussão



Análise Exploratória de Dados (EDA)

Análises estatísticas

Modelagem preditiva



Resultados e discussão

EDA





Resultados e discussão

EDA



Resultados e discussão

EDA



Resultados e discussão

Análises Estatísticas

Distribuição conjunta de **frequências absolutas**:
Diagnóstico por Resultados

Diagnóstico	Deteriorated	Improved	No Change	Total
TB	46	44	34	124
TAG	37	53	45	135
TDM	44	32	49	125
TP	44	41	31	116
Total	171	170	159	500

Distribuição conjunta de **frequências relativas**:
Diagnóstico por Resultados

Diagnosis	Deteriorated(%)	Improved(%)	No Change(%)
TB	37.10	35.48	27.42
TAG	27.41	39.26	33.33
TDM	35.20	25.60	39.20
TP	37.93	35.34	26.72

Resultados e discussão

Análises Estatísticas

Teste Qui-Quadrado:

- Os resultados sugerem similaridade prática entre os grupos, onde variações observadas (como maior proporção de "Improved" em TAG) podem ser atribuíveis ao acaso
- O χ^2 relativamente baixo aponta para uma possível associação fraca, mesmo que significativa.

H_0 : ausência de associação

H_1 : existência de associação

p-value = 0,108 ($> 0,05$)

Não permite rejeitar $H_0 \rightarrow$ insuficiência de evidências para afirmar diferenças significativas nos resultados entre diagnósticos

$\chi^2 = 10,409$

df = 6 [(4-1)*(3-1)]

Resultados e discussão

Análises Estatísticas

Valor Observado - Esperado:

Diagnosis	Deteriorated	Improved	No Change
TB	3.592	1.84	-5.432
TAG	-9.170	7.10	2.070
TDM	1.250	-10.50	9.250
TP	4.328	1.56	-5.888

Resíduos Padronizados:

Diagnosis	Deteriorated	Improved	No Change
TB	0.551585	0.283379	-0.865038
TAG	-1.349551	1.047978	0.315929
TDM	0.191180	-1.610626	1.467145
TP	0.687140	0.248403	-0.969450


Coeficiente de Contingência = 0.14
V de Cramer(φ_c) = 0.10

Efeito desprezível (valores < 0.3)
→ consistentes com o teste Qui-Quadrado não significativo ($p=0.108$)

Resultados e discussão


Análises Estatísticas

- Maior taxa de melhora em TAG e menor em TDM
- Diferenças não significativas ($p=0.108$)
- Resultados sugerem influência de fatores individuais (clínicos, genéticos, ambientais e comportamentais)
- Reforça a importância de abordagens personalizadas em saúde mental



Resultados e discussão

Análises Estatísticas



- Ausência de associações lineares relevantes (todas $|r| < 0.1$)
- Sintomas, humor, sono e estresse atuam de forma independente
- Modelo preditivo deve considerar cada dimensão separadamente
- Possíveis relações não lineares podem existir e requerem investigação

Resultados e discussão

Análises Estatísticas

Normalidade das variáveis

- Symptom Severity e Mood Score não seguem distribuição normal
 - Shapiro-Wilk ($p < 0.001$)
 - Kolmogorov-Smirnov ($p < 0.001$)

Comparação entre diagnósticos

- Symptom Severity: sem diferenças significativas
- Kruskal-Wallis: $H = 2.65$; $p = 0.4488$
- Sintomas similares entre diagnósticos

Resultados e discussão

Análises Estatísticas

Outros testes: sem relações significativas entre as variáveis testadas

- Mood Score × Diagnóstico → $p = 0.563$
- Therapy Type × Resultado → $p = 0.145$
- Sleep Quality × Stress Level → $p = 0.403$

Nível de estresse entre diagnósticos

- Estresse elevado e uniforme entre grupos
 - ANOVA: $F(3,500)=0.19$; $p=0.906$
 - Kruskal-Wallis: $H=0.58$; $p=0.901$
- Sugere influência maior de fatores externos

Resultados e discussão

Análises Estatísticas

Resultados por diagnóstico

Medianas semelhantes (7–8) para todos os grupos

- Desvios-padrão consistentes
- **Tipo de terapia e resultado**
- Distribuição similar entre abordagens – sugere ausência de relação clinicamente relevante
 - $\chi^2(6)=9.56$; $p=0.145$
 - V de Cramer (φ_c)=0.10 → efeito pequeno

Resultados e discussão

Modelagem preditiva

Regressão Logística Multinomial

Random Forest


Gradient Boosting

Resultados e discussão

Modelagem preditiva

Regressão Logística Multinomial

Configuração do modelo



- Variável dependente: **Outcome** ("Deteriorated", "Improved", "No Change")
- Variáveis numéricas avaliadas: *Age, Symptom Severity, Mood Score, Sleep Quality, Physical Activity, Treatment Duration, Stress Level, Treatment Progress, Adherence to Treatment*

Testes realizados

- **Normalidade (Shapiro-Wilk):** $p < 0.001$ para todas as variáveis → **não normalidade confirmada**
- **ANOVA - relação entre essas variáveis e a variável dependente:** maioria **sem diferenças significativas** entre grupos de Outcome
 - Exceção: **Age** ($p=0.0227$) → possível influência da idade no desfecho

Resultados e discussão

Modelagem preditiva

Regressão Logística Multinomial

Resumo ANOVA (p-valores)


- Age: 0.0227 ✓
- Demais variáveis: $p > 0.05$ ✗

Desempenho do modelo

- Acurácia $\approx 34\%$ (nível próximo à aleatoriedade)
- *Precision / Recall / F1-score* baixos e equilibrados

Conclusões

- Regressão logística **limitada** para predição de desfechos clínicos
- **Transformações ou modelos alternativos** são recomendados
- Corrobora estudos prévios que apontam **baixa performance** da regressão logística em saúde mental (Christodoulou et al., 2019; Franken et al., 2023)




Resultados e discussão

Modelagem preditiva

Random Forest

Sobre o modelo

- Algoritmo baseado em múltiplas árvores de decisão
- Captura relações complexas e não lineares
- Dispensa pressupostos de normalidade e linearidade
- Indicado após baixo desempenho da regressão logística



Pré-processamento dos dados

- One-hot encoding para variáveis categóricas
- Remoção de colunas não relevantes
- Distribuição balanceada das classes:
 - Improved: 34.0%
 - Deteriorated: 34.2%
 - No Change: 31.8%

Resultados e discussão

Modelagem preditiva


Random Forest

Desempenho do modelo

- **Acurácia: 34%** (semelhante à aleatoriedade)
- *Precision / Recall / F1-score* próximos entre classes

Interpretação

- Variáveis clínicas e sociodemográficas **não foram preditivas o suficiente**
- Resultados indicam **baixa discriminação** entre desfechos



Perspectivas e literatura

- Desempenho melhora com:
 - Dados clínicos e comportamentais mais ricos
 - **Engenharia de features e ajuste de hiperparâmetros**
- Estudos prévios relatam alta acurácia com abordagens híbridas:
 - Mohamed et al. (2023): **98,1%** (ansiedade + lógica fuzzy)
 - Suárez et al. (2025): **93,4%** (bipolaridade + EEG)

Resultados e discussão

Modelagem preditiva


Gradient Boosting

Sobre o modelo

- Combina **modelos fracos de forma sequencial**, otimizando erros residuais
- Captura **relações não lineares e interações complexas**
- Permite **ajuste fino via hiperparâmetros**, ideal para dados heterogêneos

Pré-processamento dos dados

- Mesmo padrão dos modelos anteriores
 - **One-hot encoding** de variáveis categóricas
 - Exclusão de colunas irrelevantes
 - **Divisão treino/teste: 70% / 30%**
- Distribuição de classes **equilibrada** → sem necessidade de balanceamento adicional



Resultados e discussão

Modelagem preditiva

Gradient Boosting

Desempenho do modelo

- **Acurácia:** 34%, semelhante à Regressão Logística e Random Forest
- *Precision / Recall / F1-score* equilibrados, sem ganho preditivo relevante

Evidências da literatura


Borelli et al. (2025): $F1 = 0.74$ com LightGBM + sensores passivos

Xu et al. (2025): melhora na **predição de depressão** usando dados longitudinais + Gradient Boosting

Reforça a importância da **integração de múltiplas fontes de dados e modelagem avançada** em saúde mental

Interpretação

- Variáveis disponíveis **não forneceram informação suficiente** para diferenciar desfechos
- **Modelos mais ricos e multidimensionais** tendem a apresentar desempenho superior



Considerações finais

Síntese dos Resultados

- O estudo explorou **modelos preditivos** para apoiar a prescrição de tratamentos em **saúde mental**, usando **dados sintéticos** de pacientes com TDM, TAG, TB e TP.
- Apesar do uso de **Regressão Logística, Random Forest e Gradient Boosting**,
 - a **acurácia foi de apenas 34%**, próxima ao acaso.
- A baixa performance foi atribuída a:
 - Homogeneidade dos dados sintéticos
 - Ausência de relações significativas entre variáveis
 - Falta de informações clínicas detalhadas (histórico, comorbidades etc.)

Considerações finais

Interpretação dos Resultados

- A EDA mostrou distribuições artificiais e homogêneas, pouco representativas da população real.
- Os três modelos falharam em prever outcomes (“Improved”, “Deteriorated”, “No Change”).
- Apenas a idade teve associação significativa ($p = 0,0227$).
- O problema está nos dados, não nos algoritmos.
- Destaca-se a importância da coleta de dados reais — ex.: prontuários eletrônicos do SUS — para construção de modelos aplicáveis à prática clínica.

Considerações finais

Conclusões e Perspectivas Futuras

- Estrutura metodológica proposta pode orientar futuros sistemas de apoio à decisão clínica.
- Dados sintéticos são úteis apenas para testes preliminares.
- Avanço da IA em saúde mental depende de:
 - Bancos de dados integrados e padronizados (SUS + hospitais universitários)
 - Validação clínica rigorosa e atualização constante
- Nenhum dos 1.248 dispositivos de IA aprovados pelo FDA (2025) é voltado à psiquiatria → grande oportunidade de pesquisa e inovação.
- Caminho futuro: “Medicina de precisão em saúde mental”, integrando dados clínicos, genéticos e digitais.

Obrigada!