

Modelo Preditivo para Identificação da Melhor Condução no Tratamento de Doenças Mentais

Renata de Oliveira Valentim¹; Gabrielle Maria Romeiro Lombardi²

1 Farmacêutica, Analista de Farmacovigilância. Rua Bragança Paulista, 409 – Vila Cruzeiro; 04727000 São Paulo, São Paulo, Brasil

2 PECEGE, Doutora em Genética e Melhoramento de Plantas. Rua Alexandre Herculano, 120 - Vila Monteiro; 13418-445; Piracicaba, São Paulo, Brasil

*autor correspondente: renata.valentim89@gmail.com

Modelo Preditivo para Identificação da Melhor Condução no Tratamento de Doenças Mentais

Resumo

Os transtornos mentais, como Transtorno Depressivo Maior (TDM), Transtorno de Ansiedade Generalizada (TAG), Transtorno Bipolar (TB) e Transtorno de Pânico (TP), afetam milhões de pessoas no mundo, impactando significativamente a qualidade de vida e a produtividade. Apesar de serem tratáveis, desafios como subdiagnóstico, estigma e resposta variável ao tratamento dificultam a obtenção de melhores resultados clínicos.

Este estudo explorou o potencial da inteligência artificial na personalização de tratamentos para esses transtornos, com o objetivo de desenvolver um sistema que, a partir de variáveis como idade, gênero e diagnóstico, sugerisse a melhor combinação terapêutica (medicação, terapia e exercício físico).

Inicialmente, foram realizadas análises estatísticas (ANOVA, Shapiro-Wilk, Qui-Quadrado, Kruskal-Wallis, Spearman) para investigar associações e diferenças entre variáveis clínicas e desfechos. Em seguida, testaram-se modelos de machine learning (Regressão logística multinomial, Random Forest, Gradient Boosting), validados por métricas clínicas (precisão, recall). Os modelos apresentaram desempenho não satisfatório (acurácia ~35%), revelando limitações dos dados sintéticos como ausência de relações significativas entre variáveis (p-valores > 0.05), distribuição não-normal ($p < 0.001$) e falta de variáveis críticas (ex.: histórico familiar, biomarcadores). Embora o modelo não tenha sido viável com dados artificiais, o estudo propõe uma estrutura para futuros sistemas de apoio clínico com coleta padronizada de dados eletrônicos (prontuários, aplicativos de saúde), criação de bancos de dados nacionais anonimizados e modelos treinados em populações específicas (ex.: mulheres com depressão). Por fim, esse trabalho destacou o potencial transformador caso implementado: Um sistema preditivo real, alimentado por dados diversificados que poderá auxiliar profissionais a escolherem terapias com base em evidências populacionais, reduzindo tentativa e erro no tratamento.

Palavras-chave: Machine learning; saúde mental; LGPD; dados anonimizados; SUS.

Introdução

A saúde mental é um componente essencial para o bem-estar, permitindo que os indivíduos lidem com o estresse, desenvolvam suas habilidades e participem ativamente na sociedade. No entanto, apesar de muitos transtornos mentais serem tratáveis e de baixo custo, os sistemas de saúde frequentemente enfrentam desafios como subfinanciamento, acesso limitado e, muitas vezes, cuidados de baixa qualidade. Além disso, pessoas com transtornos mentais não só enfrentam dificuldades no acesso ao tratamento, mas também lidam com o estigma, a discriminação e, em alguns casos, com violações de direitos humanos, o que agrava ainda mais a situação (WHO, 2025).

Estima-se que, em 2019, cerca de 970 milhões de pessoas no mundo viviam com transtornos mentais, sendo a ansiedade e a depressão os mais prevalentes. A pandemia de COVID-19 exacerbou essa situação, elevando em 25% a prevalência global desses transtornos (WHO, 2022). Os impactos não se restringem apenas à saúde, mas também geram enormes perdas de produtividade, que muitas vezes superam os custos diretos do tratamento. Entre 2014 e 2024, mais de 470 mil afastamentos no Brasil foram atribuídos a transtornos mentais, conforme dados do Ministério da Previdência Social (Casemiro et al., 2025).

A crise na saúde mental também afeta diversos profissionais, especialmente aqueles com alta carga de estresse, como enfermeiros, professores e policiais. Estudos indicam que os enfermeiros enfrentam um risco elevado de ansiedade, depressão e Burnout devido à sobrecarga de trabalho, à exposição à doença e à morte (Luz et al., 2021). Além disso, 75% dos professores relataram transtornos psíquicos menores, e 44% foram diagnosticados com depressão (Caldas et al., 2025). No aspecto de gênero, as mulheres têm uma prevalência maior de transtornos como ansiedade e depressão, enquanto os homens, embora menos diagnosticados, apresentam maior risco de suicídio e comportamentos impulsivos. Fatores como a sobrecarga de trabalho doméstico e as dificuldades dos homens em buscar ajuda contribuem para essas disparidades (Morais et al., 2025). Estudos apontam que o Transtorno Depressivo Maior (TDM) (Salk et al., 2018), o Transtorno de Ansiedade Generalizada (TAG) (Vesga-López et al., 2016) e o Transtorno de Pânico (TP) (McLean et al., 2011) ocorrem aproximadamente duas vezes mais em mulheres do que em homens.

O TDM caracteriza-se pela perda de prazer em atividades diárias, alterações no apetite e no sono. O Transtorno Bipolar (TB) envolve oscilações de humor entre episódios de mania e depressão. O TAG manifesta-se por preocupações excessivas e persistentes, enquanto o TP é marcado por crises súbitas de medo intenso.

Os tratamentos para TDM, TB, TAG e TP incluem medicamentos, como antidepressivos e ansiolíticos, e terapias psicossociais, como a Terapia Cognitivo-Comportamental (TCC) (Mayo Clinic, 2025). Embora já levem em conta aspectos individuais, como histórico clínico, perfil de sintomas, gênero e adesão prévia ao tratamento (Češková et al., 2020), ainda há limitações na integração de variáveis genéticas, ambientais e comportamentais, o que pode comprometer a eficácia terapêutica. Essa lacuna evidencia a necessidade de modelos de saúde mental de precisão, capazes de combinar diferentes fontes de dados clínicos e psicossociais para orientar intervenções mais individualizadas (Quinlan et al., 2020; Pulciani et al., 2017; Bickman et al., 2014).

Sob essa perspectiva, os avanços em inteligência artificial (IA) oferecem oportunidades para superar essas limitações, permitindo analisar grandes volumes de dados clínicos, comportamentais e genéticos e prever quais combinações de tratamento serão mais eficazes para cada paciente. Ferramentas inteligentes podem apoiar médicos e farmacêuticos na escolha de medicamentos, ajuste de dosagens e prevenção de interações perigosas, enquanto soluções digitais, como aplicativos e dispositivos eletrônicos, ampliam o acesso a intervenções personalizadas e monitoramento contínuo, integrando de forma mais completa os diversos componentes do cuidado em saúde mental (Lobo, 2017).

Neste estudo, foram empregados três modelos de machine learning para análise dos dados e proposição de condutas terapêuticas: a Regressão Logística, o Random Forest e o Gradient Boosting. A Regressão Logística é um modelo clássico, amplamente utilizado para classificação binária e multinomial, reconhecido por sua simplicidade e interpretabilidade, sendo útil como referência para comparação com métodos mais avançados (Favero et al., 2024). O Random Forest, por sua vez, é um algoritmo baseado em múltiplas árvores de decisão, capaz de capturar relações complexas e não lineares entre variáveis, além de ser robusto a outliers e variáveis categóricas (Breiman, 2001). Já o Gradient Boosting consiste em um método de ensemble que constrói classificadores de forma sequencial, otimizando os erros residuais e oferecendo alta capacidade preditiva, especialmente útil em conjuntos de dados heterogêneos (Friedman, 2001). A escolha desses modelos permitiu avaliar diferentes abordagens para identificar padrões e propor recomendações personalizadas no tratamento dos transtornos mentais analisados.

Nesse contexto, surge a oportunidade de integrar as terapias tradicionais com soluções inovadoras que possam otimizar os tratamentos, como os digicêuticos, que podem ser softwares, aplicativos, hardwares, dispositivos eletrônicos, algoritmos e bases de informação destinados à saúde (artigo 3º, Resolução 10 Conselho Federal de Farmácia). Esses produtos incluem aplicativos de saúde mental e dispositivos eletrônicos que proporcionam novas formas de tratamento e monitoramento. Um exemplo dessa inovação é

a Terapia de Exposição à Realidade Virtual (VRET), que tem demonstrado eficácia no tratamento de transtornos como o Transtorno de Estresse Pós-Traumático (TEPT) (Eskandar, 2024).

Diante deste cenário, esta pesquisa tem como objetivo realizar uma análise estatística dos dados disponíveis e propor um modelo preditivo para apoiar a melhor condução do tratamento de pacientes com TDM, TAG, TB e TP. Para isso, são utilizados diferentes algoritmos de machine learning, avaliando seu desempenho na identificação das combinações mais eficazes de tratamento, psicoterapia e exercício físico, considerando variáveis como idade e gênero. Espera-se, assim, contribuir para a personalização do cuidado em saúde mental e ampliar as possibilidades de acesso a condutas terapêuticas inovadoras e baseadas em evidências.

Material e Métodos

Tipo de Pesquisa

A pesquisa conduzida caracterizou-se como uma pesquisa experimental com foco na análise de dados secundários. O estudo utilizou dados sintéticos de pacientes diagnosticados com transtornos mentais, com o objetivo de desenvolver e testar um modelo preditivo para identificar o melhor tratamento e terapia, incluindo intervenções digitais, como terapias baseadas em aplicativos de meditação ou mindfulness.

Coleta de Dados

A coleta de dados foi realizada a partir do conjunto de dados “Mental Health Diagnosis and Treatment Monitoring” – Diagnóstico e Monitoramento de Tratamento de Saúde Mental, disponível no Kaggle e que contém informações relacionadas a pacientes diagnosticados com distúrbios mentais (Link para o dataset: <https://www.kaggle.com/datasets/uom190346a/mental-health-diagnosis-and-treatment-monitoring>). As variáveis analisadas encontram-se na Tabela 1.

Tabela 1. Descrição das variáveis

Termo original em inglês descrito no dataset	Tradução livre (adotada neste trabalho)	Tipo de dado
Patient ID	ID do Paciente	Inteiro/ Numérico
Age	Idade	Inteiro/ Numérico
Gender	Gênero	Texto/Categórico
Diagnosis	Diagnóstico	Texto/Categórico
Symptom Severity (1-10)	Gravidade dos Sintomas (1-10)	Inteiro/ Numérico
Mood Score (1-10)	Pontuação de Humor (1-10)	Inteiro/ Numérico
Sleep Quality (1-10)	Qualidade do Sono (1-10)	Inteiro/ Numérico
Physical Activity (hrs/week)	Atividade Física (horas/semana)	Inteiro/ Numérico
Medication	Medicação	Texto/Categórico
Therapy Type	Tipo de Terapia	Texto/Categórico
Treatment Start Date	Data de Início do Tratamento	Texto/Categórico
Treatment Duration (weeks)	Duração do Tratamento (semanas)	Inteiro/ Numérico
Stress Level (1-10)	Nível de Estresse (1-10)	Inteiro/ Numérico
Outcome	Resultado	Texto/Categórico
Treatment Progress (1-10)	Progresso do Tratamento (1-10)	Inteiro/ Numérico
AI-Detected Emotional State	Estado Emocional Detectado por IA	Texto/Categórico
Adherence to Treatment (%)	Adesão ao Tratamento (%)	Inteiro/ Numérico

Fonte: Dados originais da pesquisa

Análise Exploratória de Dados (EDA)

A análise exploratória de dados (EDA) foi conduzida com o objetivo de compreender melhor as relações entre as variáveis presentes no dataset. A EDA incluiu:

- Análise de distribuição de variáveis como idade, gênero, diagnóstico, tipo de medicação, terapia aplicada e exercício físico
- Identificação de correlações entre a taxa de sucesso do tratamento e os diferentes fatores (idade, gênero, diagnóstico, tipo de medicação, terapia e exercício físico)
- Visualizações gráficas para explorar padrões e outliers, utilizando ferramentas como matplotlib e seaborn no Python.
- Testes estatísticos, como o ANOVA ou t-test, para verificar a significância das diferenças entre grupos de tratamentos e terapias.

Modelagem Preditiva

Com base nas variáveis identificadas, foi desenvolvido um modelo preditivo para prever a eficácia do tratamento, terapia e a necessidade de exercício físico para cada paciente, com base nas características individuais (idade, gênero, diagnóstico). Os modelos de machine learning testados foram implementados utilizando a biblioteca scikit-learn. Os modelos utilizados, o motivo de uso e os parâmetros estão especificados na Tabela 2.

Tabela 2. Resumo dos modelos utilizados, motivo de uso e parâmetros

Modelo	Motivo de uso	Parâmetros	Equações
Regressão logística multinomial	prever a probabilidade de sucesso do tratamento	random_state=42 max_iter=1000	$p_{im} = \frac{e^{z_{im}}}{\sum_{m=0}^{M-1} e^{z_{im}}}$
Random Forest	capturar relações não lineares entre as variáveis	random_state=42	$\hat{y} = mode\{h_1(x), h_2(x), \dots, h_T(x)\}$
Gradient Boosting	melhorar a acurácia das previsões	random_state=42	$F_M(x) = F_0(x) + \sum_{m=1}^M \gamma_m h_m(x)$

Fonte: Dados originais da pesquisa

A validação do modelo foi realizada com a divisão dos dados em conjuntos de treino e teste, e o desempenho foi avaliado por métricas como AUC (Área Sob a Curva ROC), precisão, recall e F1-score.

Considerações Éticas

Embora os dados utilizados neste estudo sejam sintéticos e não representem informações reais de pacientes, todas as práticas de coleta, análise e processamento de dados foram realizadas de acordo com as normas éticas e regulatórias para a utilização de dados em pesquisa. O uso de dados sintéticos elimina a necessidade de aprovação por um Comitê de Ética em Pesquisa (CEP), já que não envolvem informações pessoais ou sensíveis de indivíduos reais.

Resultados e Discussão

Análise Exploratória de Dados (EDA)

Na análise exploratória dos dados, observou-se uma distribuição relativamente equilibrada dos participantes entre as faixas etárias analisadas. A maior parte dos indivíduos tinha entre 19 e 60 anos, com leve predominância da faixa de 19 a 30 anos, que representou 141 participantes (28,2%). As demais faixas etárias foram compostas por 121 pessoas (24,2%) entre 31 e 40 anos, 118 (23,6%) entre 51 e 60 anos e 108 (21,6%) entre 41 e 50 anos. A única exceção foi a faixa etária de 0 a 18 anos, que correspondeu a apenas 12 participantes (2,4%), indicando baixa representatividade de crianças e adolescentes na amostra (Figura 1).




Figura 1. Distribuição por faixa etária dos pacientes diagnosticados com algum dos 4 transtornos (TAG, TDM, TB ou TP)

Fonte: Resultados originais da pesquisa

Em relação ao sexo, a amostra apresentou uma distribuição próxima do equilíbrio, com 266 participantes do sexo masculino (53,2%) e 234 do sexo feminino (46,8%) (Figura 2).




Figura 2. Distribuição por gênero dos pacientes diagnosticados com algum dos 4 transtornos (TAG, TDM, TB ou TP)

Fonte: Resultados originais da pesquisa

Quanto ao diagnóstico clínico, os transtornos mais prevalentes foram o transtorno de ansiedade generalizada, com 135 indivíduos (27%), e o transtorno depressivo maior, com 125 (25%). Em seguida, foram observados casos de transtorno bipolar em 124 participantes (24,8%) e de transtorno do pânico em 116 (23,2%) (Figura 3).




Figura 3. Distribuição por diagnóstico

Fonte: Resultados originais da pesquisa

A distribuição quanto à medicação utilizada mostrou-se relativamente homogênea entre os grupos analisados. O uso de benzodiazepínicos foi reportado por 90 participantes (18%), seguido por inibidores seletivos da recaptação de serotonina (ISRS), com 89 (17,8%). Estabilizadores de humor e antipsicóticos foram utilizados por 87 participantes cada (17,4%), enquanto antidepressivos e ansiolíticos foram mencionados por 76 (15,2%) e 71 (14,2%) participantes, respectivamente (Figura 4).




Figura 4. Distribuição por medicação utilizada pelos pacientes diagnosticados com algum dos 4 transtornos (TAG, TDM, TB ou TP)

Fonte: Resultados originais da pesquisa

No que se refere ao tipo de terapia realizada, todas as modalidades investigadas apresentaram distribuição semelhante. A terapia baseada em mindfulness foi a mais frequente, aplicada a 130 participantes (26%), seguida pela terapia dialética comportamental, com 129 (25,8%). A terapia interpessoal foi relatada por 124 participantes (24,8%), e a terapia cognitivo-comportamental, por 117 (23,4%) (Figura 5).




Figura 5. Distribuição por tipo de terapia realizada por pacientes diagnosticados com algum dos 4 transtornos (TAG, TDM, TB ou TP)

Fonte: Resultados originais da pesquisa

Por fim, a prática de atividade física semanal concentrou-se principalmente entre 4 e 10 horas por semana. O maior grupo relatou praticar entre 8 e 10 horas (123 participantes; 27,2%), seguido por 6 a 7 horas (111; 24,5%), 4 a 5 horas (115; 25,4%) e 2 a 3 horas (104; 23%). Nenhum participante declarou realizar apenas de 0 a 1 hora semanalmente, sugerindo uma amostra com nível moderado a elevado de atividade física (Figura 6).




Figura 6. Distribuição por atividade física (horas/ semana) realizada por pacientes diagnosticados com algum dos 4 transtornos (TAG, TDM, TB ou TP)

Fonte: Resultados originais da pesquisa

Análises Estatísticas: Teste Qui-Quadrado e Medidas de Contingência

Ao analisar a distribuição conjunta das frequências absolutas entre os diferentes diagnósticos (TB, TAG, TDM e TP) e os desfechos clínicos (Deteriorated - Piorou, Improved - Melhorou e No Change - sem mudança), observou-se uma relativa uniformidade na distribuição dos desfechos: 171 participantes apresentaram piora, 170 demonstraram melhora e 159 permaneceram sem alterações, totalizando 500 indivíduos avaliados. No que diz respeito aos diagnósticos, os grupos apresentaram tamanhos semelhantes, variando de 116 (TP) a 135 (TAG) (Tabela 3).

Tabela 3. Distribuição conjunta de frequências absolutas das variáveis Diagnóstico por Resultados (Deteriorated, Improved, No Change)

Diagnóstico	Deteriorated	Improved	No Change	Total
TB	46	44	34	124
TAG	37	53	45	135
TDM	44	32	49	125
TP	44	41	31	116
Total	171	170	159	500

Fonte: Resultados originais da pesquisa

Em termos proporcionais, destacou-se que o TAG concentrou a maior proporção de pacientes que apresentaram melhora no quadro clínico (39,26%), enquanto o TDM teve a maior parcela de indivíduos que não apresentaram mudança (39,20%). Já os grupos TB e TP

apresentaram percentuais mais distribuídos entre os três desfechos, sugerindo uma evolução clínica mais variada entre os participantes com esses diagnósticos (Tabela 4).

Tabela 4. Distribuição conjunta de frequências relativas das variáveis Diagnóstico por Resultados

<i>Diagnosis</i>	<i>Deteriorated(%)</i>	<i>Improved(%)</i>	<i>No Change(%)</i>
	)		
TB	37.10	35.48	27.42
TAG	27.41	39.26	33.33
TDM	35.20	25.60	39.20
TP	37.93	35.34	26.72

Fonte: Resultados originais da pesquisa

De acordo com um estudo baseado em diretrizes, meta-análises e revisões sistemáticas de estudos controlados randomizados, tanto a psicoterapia quanto a farmacoterapia demonstraram ser mais eficazes do que os grupos de controle no tratamento da ansiedade, portanto, é esperada a maior proporção de melhora observada no TAG (39,26%) (Bandelow et al., 2017).

Em relação ao TDM, no protocolo STAR*D, que avaliou pacientes ambulatoriais com transtorno depressivo maior não psicótico, mais de 50% alcançaram remissão após duas etapas de tratamento medicamentoso, com uma taxa cumulativa teórica de 67% após quatro etapas. Pacientes com maior carga de doença (depressão crônica ou comorbidades) precisaram de mais etapas, e a remissão foi associada a melhor prognóstico. Resultados de longo prazo foram menos favoráveis para aqueles que necessitam de múltiplas etapas, ressaltando a necessidade de estratégias mais eficazes e personalizadas para o tratamento em múltiplas fases (Rush et al., 2006). Isso pode justificar a maior proporção de ausência de mudança (39,20%) observada, já que o tratamento dos transtornos de depressão exige uma alta personalização e várias etapas de tratamento, o que pode ser um fator que dificulte a melhora.

Já os grupos TB e TP mostraram percentuais mais distribuídos entre os três desfechos, refletindo a variabilidade clínica desses transtornos, frequentemente descrita em revisões e meta-análises (Grande et al., 2016; Roy-Byrne et al., 2005). Essa heterogeneidade pode estar associada à complexidade diagnóstica, à resposta diferenciada a estabilizadores de humor e à presença de comorbidades, fatores já destacados em estudos prévios.

Cabe ressaltar, entretanto, que os dados analisados nesta pesquisa são sintéticos e foram estruturados de forma a padronizar o tratamento — todos os pacientes receberam uma

combinação de farmacoterapia e psicoterapia. Essa escolha por parte do criador do dataset difere da realidade clínica, onde há grande variação quanto ao uso isolado ou combinado de intervenções, bem como na duração e intensidade dos tratamentos. Assim, embora as taxas aqui apresentadas não possam ser diretamente comparadas às da literatura, a padronização adotada permitiria explorar o potencial preditivo do modelo em um cenário controlado. Dessa forma, os resultados funcionam menos como estimativas absolutas de eficácia e mais como uma prova de conceito da aplicabilidade da abordagem proposta. Mesmo assim, esses achados preliminares sugerem possíveis padrões de resposta clínica diferenciados por diagnóstico, ressaltando a relevância de análises estatísticas adicionais para investigar possíveis associações e relações significativas entre essas variáveis.

Teste Qui-Quadrado:

A análise estatística testou a associação entre o tipo de diagnóstico e o resultado do tratamento, com a hipótese nula (H_0) indicando ausência de associação e a alternativa (H_1) sugerindo existência. O p-value de 0,108 ($> 0,05$) não permitiu rejeitar H_0 , indicando insuficiência de evidências para afirmar diferenças significativas nos outcomes entre diagnósticos. Com $df = 6 [(4-1)*(3-1)]$, os resultados sugerem similaridade prática entre os grupos, onde variações observadas (como maior proporção de "Improved" em TAG) podem ser atribuíveis ao acaso. Adicionalmente, o χ^2 relativamente baixo (10,409) aponta para uma possível associação fraca, mesmo que significativa.

Análise dos resíduos e Medidas de Associação

A análise dos resíduos padronizados não identificou diferenças significativas ($|\text{resíduos}| < 2$) entre os resultados por diagnóstico, corroborando o teste Qui-Quadrado ($\chi^2(6) = 10.41$, $p = 0.108$). Embora pacientes com TAG tenham apresentado leve tendência à melhora (resíduo +1.05) e aqueles com TDM à menor melhora (resíduo -1.61), essas variações não alcançaram significância estatística.

Tabela 5. Valor Observado - Esperado:

Diagnosis	Deteriorated	Improved	No Change
TB	3.592	1.84	-5.432
TAG	-9.170	7.10	2.070
TDM	1.250	-10.50	9.250
TP	4.328	1.56	-5.888

Fonte: Resultados originais da pesquisa

Tabela 6. Resíduos Padronizados:

Diagnosis	Deteriorated	Improved	No Change
TB	0.551585	0.283379	-0.865038
TAG	-1.349551	1.047978	0.315929
TDM	0.191180	-1.610626	1.467145
TP	0.687140	0.248403	-0.969450

Fonte: Resultados originais da pesquisa

As medidas de associação complementares corroboram a ausência de relação clinicamente relevante entre diagnóstico e resultado: Coeficiente de Contingência ($C=0.14$) e V de Cramer ($\phi_c=0.10$) indicam efeito desprezível (valores <0.3), consistentes com o teste Qui-Quadrado não significativo ($p=0.108$) (Tabela 7).

Tabela 7. Resumo do coeficiente de contingência e V de Cramer

Valor	Interpretação	Medida	Limiares de Referência
0.143	Associação muito fraca	Coeficiente Contingência	0.1-0.3: Fraca
0.102	Efeito desprezível	V de Cramer	0-0.1: Irrelevante

Fonte: COHEN, 1988

A ausência de associação significativa entre diagnóstico e desfecho pode ser parcialmente explicada pelo fato de que todos os pacientes receberam algum tipo de farmacoterapia e psicoterapia, embora não necessariamente a mesma combinação de tratamento. Apesar de estudos indicarem que TAG tende a apresentar maior resposta e TDM maior dificuldade de remissão (Rush et al., 2006; Bandelow et al., 2017), a variação nas combinações terapêuticas e nas características individuais dos pacientes pode ter atenuado diferenças significativas entre os grupos. Os coeficientes de associação fracos ($C=0.14$; $\phi_c=0.10$) sugerem que fatores individuais não incluídos, como aspectos genéticos, ambientais e comportamentais, influenciam mais os desfechos, reforçando a relevância de modelos de saúde mental de precisão para personalização efetiva do cuidado (Češková & Šilhán, 2020; Bickman et al., 2014).

Relação entre Diagnóstico e Resultado

A distribuição de resultado variou entre os diagnósticos (Figura 7). Pacientes com TAG apresentaram a maior taxa de melhora (53/135 pacientes), enquanto TDM teve a menor (32/125). Entretanto, o teste Qui-Quadrado indicou que essas diferenças não foram estatisticamente significativas ($p = 0.108$), sugerindo que outros fatores além do diagnóstico

podem influenciar os resultados. Esses achados confirmam os resultados anteriores de coeficientes de associação fracos ($C=0,14$; $\phi_c=0,10$) e indicam que variáveis individuais, como histórico clínico, perfil de sintomas e características genéticas, ambientais ou comportamentais, provavelmente exercem papel relevante na resposta ao tratamento. Assim, reforça-se a importância de abordagens de saúde mental de precisão, que integrem múltiplas fontes de dados para promover intervenções mais individualizadas e eficazes (Rush et al., 2006; Bandelow et al., 2017; Češková & Šilhán, 2020).




Figura 7. Frequência de resultados por diagnóstico

Fonte: Resultados originais da pesquisa

Mapa de calor de correlações

A matriz de correlação mostrou ausência de associação linear relevante entre as variáveis clínicas (todas $|r| < 0.1$), incluindo severidade de sintomas, humor, qualidade do sono e nível de estresse. Esse resultado indica que, na amostra estudada, essas dimensões não se relacionam de forma linear significativa, reforçando a necessidade de tratar cada variável individualmente no desenvolvimento do modelo preditivo proposto neste estudo. Ao considerar cada dimensão separadamente, seria possível integrar de forma mais precisa dados clínicos e sociodemográficos para identificar combinações de tratamento, psicoterapia e exercício físico mais eficazes, alinhando-se diretamente ao objetivo de personalizar o cuidado em saúde mental. Ressalta-se que possíveis relações não lineares não foram avaliadas e podem estar presentes.




Figura 8. Correlação entre variáveis clínicas

Fonte: Resultados originais da pesquisa

Testes de Hipóteses:

- 1) Na avaliação da normalidade das variáveis numéricas (Symptom Severity, Mood Score), os testes de normalidade indicaram que ambas as variáveis analisadas não seguem uma distribuição normal. Para Symptom Severity, o teste de Shapiro-Wilk rejeitou a normalidade ($p < 0,001$), assim como o teste de Kolmogorov-Smirnov para Mood Score ($p < 0,001$).

Symptom Severity - Shapiro-Wilk; $p = 0.0000$

Mood Score - Kolmogorov-Smirnov; $p = 0.0000$

- 2) Na comparação da mediana do Symptom Severity entre diagnósticos usando Kruskal-Wallis, o teste estatístico não rejeitou a hipótese nula ($p\text{-value} > 0.05$), indicando que não houve diferenças estatisticamente significativas nas medianas de Symptom Severity entre os grupos diagnósticos analisados. Os resultados sugerem que os sintomas são similares independentemente do diagnóstico.

Kruskal-Wallis: $H = 2.65$; $p = 0.4488$

- 3) Considerando que diferenças não foram encontradas, outras variáveis dependentes foram analisadas, porém, não apresentaram relações significativas entre as variáveis testadas, $p > 0.05$ em todos os testes.

- Mood Score: difere entre diagnósticos?

Kruskal-Wallis (Mood Score): $H = 2.05$; $p = 0.5627$

- Há associação entre Therapy Type e Resultado?

Qui-Quadrado: $\chi^2(6) = 9.56$; $p = 0.1445$

- Existe relação entre Sleep Quality e Stress Level?

Spearman: $\rho = 0.038$, $p = 0.4025$

- 4) Na comparação de grupos (ANOVA/Kruskal-Wallis), o nível de estresse se mantém elevado e uniforme (variações mínimas nas médias e desvios-padrão consistentes) entre os diagnósticos avaliados, indicando que fatores externos podem ter maior influência no estresse do que o diagnóstico específico.

ANOVA: $F(3, 500) = 0.19$, $p = 0.906$

Kruskal-Wallis: $H = 0.58$, $p = 0.901$

Tabela 8. Estatísticas descritivas das variáveis por diagnóstico:

Diagnosis	Mediana (Md)	Média	Desvio padrão	Contagem
TB	8.0	7.588710	1.729759	124
TAG	8.0	7.474074	1.660919	135
TDM	7.0	7.504000	1.739596	125
TP	8.0	7.612069	1.728390	116

Fonte: Resultados originais da pesquisa

- 5) Foi observada distribuição similar dos resultados (Deteriorated/Improved/No Change) entre as abordagens analisadas (Interpersonal Therapy, Mindfulness-Based Therapy, Cognitive Behavioral Therapy e Dialectical Behavioral Therapy), sugerindo ausência de relação clinicamente relevante entre Therapy Type e Outcome – V de Cramer ($\phi_c = 0.1$) confirmou um efeito pequeno.

Qui-Quadrado: $\chi^2(6) = 9.56$, $p = 0.1445$

V de Cramer: $\phi_c = 0.10$

Modelagem Preditiva

Foram testados três modelos preditivos: Regressão logística multinomial, Random Forest e Gradient Boosting. A escolha desses modelos se justifica pelas seguintes razões:

- **Regressão logística multinomial:** Modelo base clássico para classificação binária e multinomial. Útil pela sua interpretabilidade e simplicidade. Foi selecionado como baseline para comparação com métodos mais complexos.
- **Random Forest:** Modelo baseado em árvores, robusto a outliers e multicolinearidade, não requer pressupostos de normalidade ou linearidade. Ideal para explorar interações complexas e não-lineares nos dados.
- **Gradient Boosting:** Variante mais sofisticada de ensemble, com foco em minimizar erros residuais de forma sequencial. Alta capacidade preditiva, mas maior risco de overfitting, exigindo atenção ao balanceamento de classes e ajuste de hiperparâmetros.

Modelo 1: Regressão logística multinomial

Para a análise, escolheu-se a variável dependente Outcome com três categorias (“Deteriorated”, “Improved” e “No Change”), configurando um problema de regressão logística multinomial.

Como pressupostos para este modelo, foram avaliadas as variáveis numéricas quanto à normalidade (embora não seja requisito obrigatório para regressão logística multinomial, mas útil para diagnóstico) e a relação entre essas variáveis e a variável dependente por meio de ANOVA.

Foram realizados os seguintes testes:

- Teste de normalidade Shapiro-Wilk para as variáveis numéricas: Age, Symptom Severity (1-10), Mood Score (1-10), Sleep Quality (1-10), Physical Activity (hrs/week), Treatment Duration (weeks), Stress Level (1-10), Treatment Progress (1-10) e Adherence to Treatment (%).
- ANOVA para testar a diferença das médias dessas variáveis entre as três categorias da variável Outcome.

O teste de Shapiro-Wilk indicou que todas as variáveis numéricas - Age, Symptom Severity (1-10), Mood Score (1-10), Sleep Quality (1-10), Physical Activity (hrs/week), Treatment Duration(weeks), Stress Level (1-10), Treatment Progress (1-10), Adherence to Treatment (%) - apresentaram p-valores $< 0,001$, rejeitando a hipótese de normalidade dos dados para todas elas.

Já ANOVA apresentou resultados majoritariamente não significativos ($p > 0,05$) para quase todas as variáveis, indicando que não houve diferença estatisticamente significativa

das médias entre os grupos Outcome, com exceção da variável Age, que apresentou $p = 0,0227$, sugerindo possível influência da idade no desfecho.

Tabela 9. Resultado do teste ANOVA

Variável	p-valor
Age	0.0227
Symptom severity	0.9096
Mood Score	0.6886
Sleep Quality	0.9701
Physical Activity	0.2871
Treatment duration	0.4703
Stress level	0.7993
Treatment progress	0.1315
Adherence to treatment	0.6279

Fonte: Resultados originais da pesquisa

Apesar da variável Age apresentar associação estatisticamente significativa com Outcome, a não normalidade generalizada das variáveis numéricas e a ausência de diferenças significativas para a maioria dos preditores indicam que a aplicação direta da regressão logística multinomial pode ser inadequada sem transformações ou ajustes adicionais.

Além disso, os resultados preliminares do modelo indicaram uma acurácia próxima à aleatoriedade (cerca de 34%), reforçando a necessidade de explorar modelos alternativos mais robustos a essas condições (Tabela 10).

Tabela 10. Output do Modelo Regressão logística multinomial

	Precision	Recall	F1-score	Support
Deteriorated	0.38	0.33	0.35	55
Improved	0.33	0.29	0.31	48
No Change	0.32	0.40	0.36	47
accuracy			0.34	150
macro avg	0.34	0.34	0.34	150
weighted avg	0.34	0.34	0.34	150

Fonte: Resultados originais da pesquisa

As curvas ROC (Figura 9) confirmam o desempenho limitado do modelo, com AUC moderado no treino e valores próximos ao acaso no teste, reforçando a dificuldade de discriminação entre os desfechos.

Curvas ROC - Regressão Logística (One-vs-Rest)




Figura 9. Curvas ROC do modelo Regressão Logística Multinomial (One-vs-Rest), com AUC por classe e linha de referência aleatória.

Fonte: Resultados originais da pesquisa

Esses resultados estão de acordo com estudos prévios, que indicam que a regressão logística multinomial pode apresentar desempenho limitado na predição de desfechos clínicos em saúde mental quando baseada apenas em dados clínicos e sociodemográficos tradicionais, reforçando a necessidade de explorar modelos mais robustos capazes de capturar interações complexas entre variáveis (Christodoulou et al., 2019; Franken et al., 2023).

Modelo 2: Random Forest

Considerando que a regressão logística multinomial apresentou baixo desempenho, o Random Forest foi escolhido por sua flexibilidade e capacidade de generalização. Primeiramente, foi realizado o pré-processamento das variáveis categóricas usando one-hot encoding e colunas não relevantes para o modelo foram removidas. A distribuição das classes do Outcome em treino mostrou-se balanceada:

Distribuição de classes por outcome:

Improved: 34,0%

Deteriorated: 34,2%

No Change: 31,8%

Este balanceamento razoável diminuiu a necessidade de técnicas adicionais para correção de desequilíbrio.

O modelo Random Forest foi treinado e avaliado e os resultados da classificação foram:

Tabela 11. Output do Modelo Random Forest

	Precision	Recall	f1-score	support
Deteriorated	0.41	0.44	0.42	55
Improved	0.29	0.33	0.31	48
No Change	0.30	0.23	0.26	47
accuracy			0.34	150
macro avg	0.33	0.33	0.33	150
weighted avg	0.34	0.34	0.34	150

Fonte: Resultados originais da pesquisa

O modelo Random Forest apresentou uma acurácia de 34%, próxima à distribuição aleatória, indicando que as variáveis avaliadas podem não ser suficientemente preditivas para distinguir entre os desfechos.

As curvas ROC (Figura 10) mostram forte overfitting (AUC perfeito no treino), porém desempenho equivalente ao acaso no teste, evidenciando baixa capacidade de generalização com as variáveis disponíveis.

Curvas ROC - Random Forest (One-vs-Rest)




Figura 10. Curvas ROC do modelo Random Forest (One-vs-Rest) para treino e teste, com AUC por classe e linha de referência aleatória

Fonte: Resultados originais da pesquisa

Estudos prévios em saúde mental sugerem que o desempenho de Random Forest pode ser significativamente maior quando há dados clínicos mais detalhados, biomarcadores ou informações comportamentais adicionais, bem como ajustes finos de hiperparâmetros e engenharia de features. Por exemplo, Mohamed et al. (2023) alcançaram uma acurácia de 98,13% na previsão de estágios de ansiedade utilizando Random Forest em um modelo híbrido com lógica fuzzy. Da mesma forma, Suárez et al. (2025) reportaram uma acurácia de 93,41% na classificação de transtorno bipolar com base em dados de EEG.

Modelo 3: Gradient Boosting

O modelo Gradient Boosting foi selecionado por sua capacidade de construir classificadores poderosos a partir da combinação sequencial de modelos fracos, otimizando iterativamente os erros residuais. Essa técnica é especialmente útil para capturar relações não lineares e interações complexas entre variáveis, características comuns em dados de saúde mental. Além disso, o Gradient Boosting oferece flexibilidade no ajuste fino por meio de hiperparâmetros, o que pode ser vantajoso para maximizar a performance em datasets heterogêneos.

O pré-processamento dos dados manteve o mesmo padrão dos modelos anteriores, com codificação one-hot das variáveis categóricas, exclusão de colunas irrelevantes e divisão do dataset em conjuntos de treino (70%) e teste (30%). A distribuição das classes no conjunto de treino mostrou-se relativamente equilibrada, não sendo aplicadas técnicas adicionais para balanceamento.

O treinamento e avaliação do modelo foram realizados e os resultados obtidos foram:

Tabela 12. Output do Modelo Gradient Boosting

	Precision	Recall	F1-score	support
Deteriorated	0.41	0.27	0.33	55
Improved	0.33	0.38	0.35	48
No Change	0.31	0.38	0.34	47
accuracy			0.34	150
macro avg	0.35	0.34	0.34	150
weighted avg	0.35	0.34	0.34	150

Fonte: Resultados originais da pesquisa

O modelo Gradient Boosting apresentou acurácia de 34%, similar aos modelos Random Forest e Regressão logística multinomial, sugerindo que as variáveis disponíveis neste estudo não forneceram informação preditiva suficiente para diferenciar os desfechos.

As curvas ROC (Figura 11) indicam comportamento similar ao Random Forest — ajuste quase perfeito no treino, mas AUC próximo ao acaso no teste — sugerindo que os dados não forneceram sinais preditivos suficientes para o modelo explorar.

Curvas ROC - Gradient Boosting (One-vs-Rest)




Figura 11. Curvas ROC do modelo Gradient Boosting (One-vs-Rest) para os conjuntos de treino e teste, com área sob a curva (AUC) calculada para cada classe e linha de referência aleatória

Fonte: Resultados originais da pesquisa

Estudos prévios demonstram que Gradient Boosting pode alcançar desempenho significativamente superior quando aplicado a conjuntos de dados mais ricos e multidimensionais. Por exemplo, um estudo com estudantes universitários utilizando dados de sensores passivos alcançou F1-score de 0,744 com Light Gradient Boosting Machine, evidenciando o potencial de integração de dados comportamentais e digitais (Borelli, et al., 2025). De forma similar, outro estudo com idosos com declínio cognitivo subjetivo obteve desempenho aprimorado na predição de depressão ao utilizar Gradient Boosting combinado com dados longitudinais detalhados (Xu et al., 2025). Esses achados reforçam a importância de integrar múltiplas fontes de informação e técnicas avançadas de modelagem para melhorar a performance preditiva em saúde mental.

Considerações Finais

O estudo buscou aplicar modelos preditivos para auxiliar na condução de tratamentos em saúde mental, utilizando dados sintéticos disponíveis em um banco de dados aberto de pacientes com transtornos como TDM, TAG, TB e TP.

Embora os algoritmos testados (Regressão Logística multinomial, Random Forest e Gradient Boosting), não tenham alcançado desempenho superior ao acaso, esse resultado não configura uma falha metodológica, mas sim um achado relevante sobre a carência de dados em saúde.

As análises estatísticas conduzidas — ANOVA, testes de normalidade, Qui-quadrado, Kruskal-Wallis e correlações — evidenciaram a ausência de relações entre variáveis clínicas e outcomes, sugerindo um cenário onde os desfechos parecem distribuídos de forma quase aleatória. Assim, os modelos preditivos atuaram como um instrumento diagnóstico sobre a qualidade e suficiência das variáveis disponíveis.

Mais do que demonstrar limitações de acurácia (~34%), os resultados indicam que a construção de modelos para suporte clínico depende menos do algoritmo escolhido e mais da profundidade, variedade e qualidade dos dados utilizados. Dessa forma, o valor deste trabalho reside em revelar um requisito crítico para projetos dessa natureza: a necessidade de sistemas consistentes de coleta, padronização e integração de dados clínicos, comportamentais e digitais.

Esse achado é coerente com a literatura que aponta a emergência da medicina de precisão em saúde mental, onde a previsibilidade dos desfechos depende da incorporação de múltiplas camadas de informação — genéticas, ambientais, históricas, psicossociais e de evolução temporal. Ao destacar a insuficiência preditiva do dataset artificial utilizado, este estudo não invalida o uso de IA na saúde mental, mas ajuda a mapear as condições mínimas para que modelos sejam eficazes.

Assim, a contribuição desta pesquisa é dupla:

- (1) metodologicamente, oferece uma estrutura replicável de pré-processamento, análise estatística e avaliação preditiva; e
- (2) conceitualmente, evidencia que avanços relevantes dependem da melhoria dos sistemas de coleta e da governança de dados em saúde.

Nesse sentido, reforça-se a importância de iniciativas como prontuários eletrônicos interoperáveis, bancos de dados nacionais anonimizados, estudos longitudinais e integração entre academia, atenção primária e tecnologia. Só a partir desta base será possível desenvolver modelos preditivos realmente úteis — capazes de apoiar decisões clínicas e reduzir a lógica de tentativa e erro ainda predominante no tratamento de transtornos mentais.

Por fim, os resultados aqui obtidos servem como alerta científico e roteiro prático: antes de otimizar modelos, é preciso otimizar dados. Essa conclusão, embora diferente do objetivo inicial de desenvolver uma ferramenta preditiva funcional, representa um insight essencial para futuras pesquisas e aplicações em inteligência artificial aplicada à saúde mental.

Agradecimentos

Agradeço ao meu parceiro de vida que sempre acredita no meu potencial e à minha orientadora por ser sempre tão disponível.

Referências

Bandelow, B.; Michaelis, S. 2017. Epidemiology of anxiety disorders in the 21st century. *Dialogues in Clinical Neuroscience* 19(2): 89-97.

Borelli, J.L.; Wang, Y.; Li, F.H.; Russo, L.N.; Tironi, M.; Yamashita, K.; Zhou, El.; Lai, J.; Nguyen, B.; Azimi, I.; Marcotullio, C.; Labbaf, S.; Jafarlou, S.; Dutt, N.; Rahmani, A. 2025. Detection of Depressive Symptoms in College Students Using Multimodal Passive Sensing Data and Light Gradient Boosting Machine: Longitudinal Pilot Study. *JMIR Form Res*(9):1

Bickman, L.; Lyon, A.R.; Wolpert, M. 2016. Achieving Precision Mental Health through Effective Assessment, Monitoring, and Feedback Processes. *Adm Policy Ment Health* 43:271–276.

Brasil. 2024. Resolução nº 10, de 2 de julho de 2024. Regulamenta as atribuições do farmacêutico na Saúde Digital e Inteligência Artificial e dá outras providências. Conselho Federal de Farmácia. *Diário Oficial da União*, Brasília, 2 jul. 2024.

Breiman, L. 2001. Random Forests. *Machine Learning* 45(1): 5–32.

Caldas, F.B.; Reis, C.P.M.; Gomes-Souza, R.; Azevedo, L.A.; Lima, K.S. 2025. Adoecimento mental em professores da educação básica: uma revisão sistemática da literatura. *Cadernos de Educação* 24(48): 1-22.

Casemiro, P.; Moura, R. 2025. Crise de saúde mental: Brasil tem maior número de afastamentos por ansiedade e depressão em 10 anos. Disponível em: <<https://g1.globo.com/trabalho-e-carreira/noticia/2025/03/10/crise-de-saude-mental-brasil-tem-maior-numero-de-afastamentos-por-ansiedade-e-depressao-em-10-anos.ghtml>>. Acesso em: 16 mar. 2025.

Češková, E.; Šilhán, P. 2021. From Personalized Medicine to Precision Psychiatry? *Neuropsychiatric Disease and Treatment*: 17 3663–3668.

Christodoulou, E., Ma, J., Collins, G. S., Steyerberg, E. W., Verbakel, J. Y., & Van Calster, B. 2019. A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. *Journal of Clinical Epidemiology*, 110, 12–22.

Cohen, J. 1988. Statistical power analysis for the behavioral sciences. 2 ed. New York: Routledge.

Eskandar, K. 2024. The impact of virtual reality exposure therapy in the treatment of PTSD and anxiety disorders. *Debates em Psiquiatria* 14: 1-21.

Favero, L. P., Belfiore, P. 2024. Manual de Análise de Dados: Estatística e Machine Learning com Excel, SPSS, Stata, R e Python. GEN LTC.

Franken, K., ten Klooster, P., Bohlmeijer, E., Westerhof, G., & Kraiss, J. (2023). Predicting non-improvement of symptoms in daily mental healthcare practice using routinely collected patient-level data: a machine learning approach. *Frontiers in Psychiatry*, 14, 1236551

Friedman, J.H. 2001. Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics* 29(5): 1189–1232.

Grande, I.; Berk, M.; Birmaher, B.; Vieta, E. 2016. Bipolar disorder. *The Lancet* 387(10027): 1561-1572.

Lobo, L.C. 2017. Inteligência Artificial e Medicina. *Revista Brasileira de Educação Médica* 41(2): 185-193.

Luz, D.C.R.P.; Campos, J.R.E.; Bezerra, P.O.S.; Campos, J.B.R.; Nascimento, A.M.V.; Barros, A.B. 2021. Burnout e saúde mental em tempos de pandemia de COVID-19: revisão sistemática com metanálise. *Revista Nursing* 24(276): 5714-5719.

MAYO CLINIC. Mood disorders. Disponível em: <https://www.mayoclinic.org/diseases-conditions/mood-disorders/symptoms-causes/syc-20365057>. Acesso em: 27 mar. 2025.

Moggia, D.; Lutz, W.; Brakemeier, E.-L.; Bickman, L. 2024. Treatment Personalization and Precision Mental Health Care: Where are we and where do we want to go? *Administration and Policy in Mental Health and Mental Health Services Research* 51(5): 611–616.

Mohamed, E. S.; Naqishbandi, T.A.; Bukhari, S.A.C; Sawrikar, I.R.V.; Hussain, A. 2023. A hybrid mental health prediction model using Support Vector Machine and Random Forest. *Healthcare Analytics: v3(2023)100185*.

McLean, C.P.; Asnaani, A.; Litz, B.T.; Hofmann, S.G. 2011. Gender differences in anxiety disorders: prevalence, course of illness, comorbidity and burden of illness. *Journal of Psychiatric Research* 45(8): 1027–1035.

Morais, K.M.A.; Omes, J.A.; Batista, M.H.; Bezerra, A.P.A.M.; Gascón, S. 2025. Diferenças de gênero em transtornos mentais comuns e pensamentos suicidas entre trabalhadores formais no Brasil. *Saúde Coletiva (Edição Brasileira)* 15(93): 14869-14874.

Pulciani, S.; Di Lonardo, A.; Fagnani, C.; Taruscio, D. 2017. P4 medicine versus Hippocrates. *Ann Ist Super Sanita*: 53(3):185–191.

Quinlan, E.B.; Banaschewski, T.; Barker, G.J., 2020. IMAGEN Consortium. Identifying biological markers for improved precision medicine in psychiatry. *Mol Psychiatry*: 25(2):243–253.

Roy-Byrne, P.P.; Craske, M.G.; Stein, M.B. 2005. Panic disorder. *The Lancet* 365(9458): 1023-1032.

Rush, A.J.; Trivedi, M.H.; Wisniewski, S.R.; Nierenberg, A.A.; Stewart, J.W.; Warden, D.; Niederehe, G.; Thase, M.E.; Lavori, P.W.; Lebowitz, B.D.; McGrath, P.J.; Rosenbaum, J.F.; Sackeim, H.A.; Kupfer, D.J.; Luther, J.; Fava, M. 2006. Acute and longer-term outcomes in depressed outpatients requiring one or several treatment steps: a STAR*D report. *American Journal of Psychiatry* 163(11): 1905-1917.

Salk, R.H.; Hyde, J.S.; Abramson, L.Y. 2017. Gender differences in depression in representative national samples: meta-analyses of diagnoses and symptoms. *Psychological Bulletin* 143(8): 783–822.

Suárez, M., Torres, A.M.; Segura, P.B.; Mateo, J. 2025. Application of the Random Forest Algorithm for Accurate Bipolar Disorder Classification. *Life* 2025, 15(3), 394.

U.S. Food and drug administration (FDA). 2025. Artificial Intelligence-Enabled Medical Devices. Disponível em <<https://www.fda.gov/medical-devices/software-medical-device-samd/artificial-intelligence-enabled-medical-devices>>. Acesso em 03 set. 2025.

Vesga-López, O.; Schneier, F.; Wang, S.; Heimberg, R.; Liu, S.M.; Hasin, D.S.; Blanco, C. 2008. Gender differences in generalized anxiety disorder: results from the National Epidemiologic Survey on Alcohol and Related Conditions (NESARC). *Journal of Clinical Psychiatry* 69(10): 1606–1616.

WORLD HEALTH ORGANIZATION (WHO). 2022. Early evidence of the pandemic's impact: Scientific brief. Disponível em <https://www.who.int/publications/i/item/WHO-2019-nCoV-Sci_Brief-Mental_health-2022.1>. Acesso em 16 mar. 2025.

WORLD HEALTH ORGANIZATION (WHO). 2025. Mental health. Disponível em: <<https://www.who.int/health-topics/mental-health>>. Acesso em: 27 mar. 2025.

Xu, J.; Zhang, W. 2025. A machine learning-based approach to predict depression in Chinese older adults with subjective cognitive decline: a longitudinal study. Scientific Reports(15): 26985.